MAT02025 - Amostragem 1

AAS: variâncias dos estimadores

Rodrigo Citton P. dos Reis citton.padilha@ufrgs.br

Universidade Federal do Rio Grande do Sul Instituto de Matemática e Estatística Departamento de Estatística

Porto Alegre, 2021



Relembrando

Relembrando

Relembrando

Propriedades dos estimadores

Teorema 9.1

A média amostral \overline{y} é uma estimativa sem tendência para \overline{Y} .

Variâncias dos estimadores

Normalmente, a variância de Y₁, em uma população finita, é definida por

$$\sigma^2 = \frac{\sum_{i=1}^{N} (Y_i - \overline{Y})^2}{N}.$$

▶ Por uma questão de notação, os resultados são apresentados de acordo com uma expressão ligeiramente diferente, na qual usa-se o divisor (N − 1) em lugar de N. Assim, temos

$$S^2 = \frac{\sum_{i=1}^{N} (Y_i - \overline{Y})^2}{N-1}.$$

Examinamos, agora, a variância de \overline{y} . Isso quer dizer $E[(\overline{y} - \overline{Y})^2]$, tomado dentre todas as ${}_{N}C_{n}$.

Teorema 10.1

A variância do valor médio, \overline{y} , de uma amostra aleatórica simples é dada pela fórmula:

$$\operatorname{Var}(\overline{y}) = \operatorname{E}\left[(\overline{y} - \overline{Y})^2\right] = \frac{S^2}{n} \frac{(N - n)}{N} = \frac{S^2}{n} (1 - f),$$

em que f = n/N é a fração de amostragem.

Demonstração. Mais uma vez, vamos utilizar o método sugerido por **Cornfield** $(1944)^1$. Neste caso, representamos a média amostral por

$$\overline{y} = \frac{1}{n} \sum_{i=1}^{N} a_i Y_i,$$

em que o somatório abrange todas as N unidades da população.

 $^{^1}$ Cornfield, J. (1944). On Samples from Finite Populations. Journal of the American Statistical Association, 39(226), 236.

- ▶ Lembre que, nesta representação da média amostral, os a_i são variáveis aleatórias (a_i = 1, se i-ésima unidade da população é selecionada para a amostra; e a_i = 0, caso contrário), e os Y_i constituem um conjunto de números fixos.
- Ainda, temos que ai é uma variável aleatória com distribuição Bernolli com

$$\mathsf{E}\left(a_{i}\right) = P = \frac{n}{N}, \quad \mathsf{Var}\left(a_{i}\right) = \frac{n}{N}\left(1 - \frac{n}{N}\right).$$

► A covariância de a_i e a_j é, por definição,

$$Cov(a_i, a_j) = E\{[a_i - E(a_i)][a_j - E(a_j)]\} = E(a_i a_j) - E(a_i)E(a_j).$$

- Note que $a_i a_j$ é igual a 1 se as unidades i e j estiverem na amostra, ou é 0, caso contrário.
 - ▶ Logo, $E(a_i a_j) = 1 \times Pr(a_i a_j = 1) + 0 \times Pr(a_i a_j = 0) = Pr(a_i a_j = 1) = Pr(a_i = 1, a_j = 1).$

A probabilidade de que duas unidades específicas estejam ambas na amostra é [n(n-1)]/[N(N-1)]. Portanto,

$$\begin{aligned} \mathsf{Cov}\left(a_{i}, a_{j}\right) &= \mathsf{E}\left(a_{i} a_{j}\right) - \mathsf{E}\left(a_{i}\right) \mathsf{E}\left(a_{j}\right) \\ &= \frac{n(n-1)}{N(N-1)} - \left(\frac{n}{N}\right)^{2} = -\frac{n}{N(N-1)} \left(1 - \frac{n}{N}\right). \end{aligned}$$

► Agora, temos que

$$\begin{aligned} \operatorname{Var}\left(\overline{y}\right) &= \operatorname{Var}\left(\frac{1}{n}\sum_{i=1}^{N}a_{i}Y_{i}\right) \\ &= \frac{1}{n^{2}}\operatorname{Var}\left(\sum_{i=1}^{N}a_{i}Y_{i}\right) \\ &= \frac{1}{n^{2}}\left[\sum_{i=1}^{N}\operatorname{Var}\left(a_{i}Y_{i}\right) + 2\sum_{i < j}\operatorname{Cov}\left(a_{i}Y_{i}, a_{j}Y_{j}\right)\right] \\ &= \frac{1}{n^{2}}\left[\sum_{i=1}^{N}Y_{i}^{2}\operatorname{Var}\left(a_{i}\right) + 2\sum_{i < j}Y_{i}Y_{j}\operatorname{Cov}\left(a_{i}, a_{j}\right)\right] \\ &= \frac{1}{n^{2}}\left[\sum_{i=1}^{N}Y_{i}^{2}\left(\frac{n}{N}\right)\left(1 - \frac{n}{N}\right) + 2\sum_{i < j}Y_{i}Y_{j}\left\{-\frac{1}{N}\frac{n}{(N-1)}\left(1 - \frac{n}{N}\right)\right\}\right] \end{aligned}$$

$$= \frac{(1-f)}{nN} \left[\sum_{i=1}^{N} Y_i^2 - \frac{1}{N-1} \sum_{i \neq j} Y_i Y_j \right]$$

$$= \frac{(1-f)}{nN} \left[\sum_{i=1}^{N} Y_i^2 + \frac{1}{N-1} \left(\sum_{i=1}^{N} Y_i^2 - N^2 \overline{Y}^2 \right) \right] \text{ (soma produtos mesma variável)}$$

$$= \frac{(1-f)}{nN} \frac{N}{(N-1)} \left[\sum_{i=1}^{N} Y_i^2 - N \overline{Y}^2 \right]$$

$$= \frac{(1-f)}{n(N-1)} \left[\sum_{i=1}^{N} (Y_i - \overline{Y})^2 \right] \text{ (soma dos desvios quadráticos)}$$

$$= \frac{S^2}{n} (1-f).$$

Para estas duas últimas identidades, ver o Capítulo 2.6, "Expressões úteis", do livro "Elementos de Amostragem" (Bolfarine e Bussab, 2005).

Corolário 10.1

O erro padrão de \overline{y} é dado pela fórmula

$$\sigma_{\overline{y}} = \frac{S}{\sqrt{n}} \sqrt{(N-n)/N} = \frac{S}{\sqrt{n}} \sqrt{1-f}.$$

Corolário 10.2

A variância de $\hat{Y}_T = N\overline{y}$, como estimativa do valor total da população Y_T , é dada pela fórmula

$$Var(\hat{Y}_T) = E[(\hat{Y}_T - Y_T)^2] = \frac{N^2 S^2}{n} \frac{(N - n)}{N} = \frac{N^2 S^2}{n} (1 - f).$$

Corolário 10.3

O erro padrão de \hat{Y}_T é calculado pela fórmula

$$\sigma_{\hat{Y}_T} = \frac{NS}{\sqrt{n}} \sqrt{(N-n)/N} = \frac{NS}{\sqrt{n}} \sqrt{1-f}.$$

Correções das populações finitas

Correções das populações finitas

Correções das populações finitas

- Para uma amostra aleatória de tamanho n, proveniente de uma **população infinita**, é sabido que a variância do valor médio é σ^2/n .
- A única modificação desse valor, quando a **população é finita**, é a introdução do fator (N n)/N.
- ▶ Os fatores (N-n)/N para a variância, e $\sqrt{(N-n)/N}$, para o erro padrão, são chamados correções das populações finitas (cpf).
 - ▶ São apresentados com o divisor (N-1), em vez N, pelos autores que dão os resultados em função de σ .

Correções das populações finitas

- ▶ Desde que a fração n/N, permaneça baixa, esses fatores ([N-n]/N)se aproximam do valor da unidade, e o tamanho da população, como tal, não tem influência direta no erro padrão do valor médio amostral.
 - Ou seja, $\frac{(N-n)}{N} = 1 \frac{n}{N} \approx 1$, quando $\frac{n}{N} \approx 0$.
 - Por exemplo, se 5 é o mesmo em duas populações, uma amostra de 500 unidades de uma população de 200.000, dá uma estimativa quase tão precisa do valor médio da população quanto uma amostra de 500 unidades de uma população de 10.000.
- Na prática, as cpf podem ser ignoradas, quando quer a fração de amostragem não exceda a 5% e, em muitos casos, até mesmo quando seu valor chegue a 10%.
 - ► A consequência de se ignorar as correções é a superestimação do erro padrão da estimativa \overline{V}
 - Pergunta: no que isto implica?

Para casa

- Refaça as demonstrações da aula de hoje.
- ▶ Utilize o **Teorema 10.1** apresentado na aula para demonstrar os **Corolários 10.1**, **10.2** e **10.3**.

Próxima aula

Estimativa do erro padrão de uma amostra e limites de confiança.

Por hoje é só!

Bons estudos!

