

# MAT02025 - Amostragem 1

## AAS: intervalos de confiança para uma proporção

Rodrigo Citton P. dos Reis  
citton.padilha@ufrgs.br

UNIVERSIDADE FEDERAL DO RIO GRANDE DO SUL  
INSTITUTO DE MATEMÁTICA E ESTATÍSTICA  
DEPARTAMENTO DE ESTATÍSTICA

Porto Alegre, 2022

IC aproximado para  $P$

## IC aproximado para $P$

- ▶ Da expressão para a variância estimada de  $P$ , uma forma da aproximação normal para os limites de confiança de  $P$  é

$$p \pm \left[ z \sqrt{1-f} \sqrt{pq/(n-1)} + \frac{1}{2n} \right],$$

em que  $f = n/N$ ,  $z$  é o desvio normal correspondente à probabilidade de confiança.

## IC aproximado para $P$

- ▶ O uso do termo mais familiar  $\sqrt{pq/n}$  não apresenta uma diferença notável.
- ▶ O último termo à direita  $(1/2n)$  é uma **correção de continuidade**.
  - ▶ Isso produz apenas uma ligeira **melhora na aproximação**.
  - ▶ No entanto, **sem a correção**, a aproximação normal geralmente fornece um **intervalo** de confiança **muito estreito**.
- ▶ **Para pensar:** intervalos com menor amplitude representam menor incerteza com respeito a estimativa do parâmetro de interesse. Por outro lado, espera-se que  $100 \times (1 - \alpha)\%$  dos intervalos de confiança de  $100 \times (1 - \alpha)\%$  contenham o verdadeiro parâmetro. Intervalos “encolhidos” podem não garantir que a **taxa de cobertura** dos ICs seja próxima à respectiva **taxa nominal**.

## IC aproximado para $P$

- ▶ O erro na aproximação normal depende de todas as quantidades  $n$ ,  $p$ ,  $N$  e  $\alpha$  ( $1 - \alpha$  é coeficiente de confiança do intervalo).
- ▶ A quantidade à qual o erro é mais sensível é  $np$ , ou mais especificamente, o número observado na menor classe.
- ▶ A tabela a seguir fornece **regras de trabalho** para decidir quando a aproximação normal pode ser usada.

$p$	$np$ = número observado na menor classe	$n$ = tamanho da amostra
0,5	15	30
0,4	20	50
0,3	24	80
0,2	40	200
0,1	60	600
0,05	70	1400
$\approx 0$	80	$\infty$

## IC aproximado para $P$

- ▶ As regras apresentadas na tabela acima são construídas de modo que, com limites de confiança de 95%, a frequência real com a qual os limites falham em incluir  $P$  não seja maior que 5,5%.
  - ▶ Ou seja, a taxa de cobertura dos ICs de 95% com base na aproximação normal (dadas as condições da tabela) não deve ser inferior a 94,5%.
- ▶ Além disso, a probabilidade de que o limite superior esteja abaixo de  $P$  está entre 2,5 e 3,5%, e a probabilidade de que o limite inferior exceda  $P$  está entre 2,5 e 1,5%.

# IC para $A$

- ▶ Para obter os limites de confiança para o parâmetro  $A$ , número de unidades que pertencem a classe  $C$  na população, multiplicamos por  $N$  os limites inferior e superior do intervalo de confiança para  $P$ .
  - ▶  $\hat{A}_I = N\hat{P}_I$  e  $\hat{A}_S = N\hat{P}_S$ .

IC exato para  $A$



## IC exato para $A$

- ▶ Os limites de confiança também podem ser obtidos com base na **distribuição hipergeométrica**.
  - ▶ **Lembrando:** esta é a **distirbuição exata** do número de unidades na amostra que pertencem a classe  $C$ ,  $a$ .
- ▶ O **método exato** de obtenção do intervalo de confiança para  $A$  é **conceitualmente simples**, mas **computacionalmente complexo**.

# IC exato para $A$

- ▶ Seja  $a = \sum_{i=1}^n Y_i$  o número de unidades pertencentes a classe  $C$  na amostra.
- ▶ Para um intervalo de confiança de  $100 \times (1 - \alpha)\%$  desejado para o número  $A$ , um limite superior  $\hat{A}_S$  é determinado como o número de unidades na população que pertencem a classe  $C$  que fornece probabilidade  $\alpha_1$  de obter  $a$  ou menos unidades que pertencem a classe  $C$  na amostra, em que  $\alpha_1$  é aproximadamente igual a metade do  $\alpha$  desejado.

## IC exato para $A$

- Ou seja,  $\hat{A}_S$  satisfaz

$$\begin{aligned}\Pr(X \leq a) &= \sum_{j=0}^a \Pr(j, n-j | \hat{A}_S, N - \hat{A}_S) \\ &= \sum_{j=0}^a \binom{\hat{A}_S}{j} \binom{N - \hat{A}_S}{n-j} / \binom{N}{n} = \alpha_1.\end{aligned}$$

## IC exato para $A$

- ▶ O limite inferior  $\hat{A}_I$  é o número de unidades na população que pertencem a classe  $C$  que fornece probabilidade  $\alpha_2$  de se obter  $a$  ou mais unidades que pertencem a classe  $C$  na amostra, em que  $\alpha_2$  é aproximadamente igual a metade do  $\alpha$  desejado.
- ▶ Ou seja,  $\hat{A}_I$  satisfaz

$$\begin{aligned} \Pr(X \geq a) &= \sum_{j=a}^n \Pr(j, n-j | \hat{A}_I, N - \hat{A}_I) \\ &= \sum_{j=a}^n \binom{\hat{A}_I}{j} \binom{N - \hat{A}_I}{n-j} / \binom{N}{n} = \alpha_2. \end{aligned}$$

- ▶ Os limites de confiança para  $P$  são então determinados, dividindo-se os limites achados para  $A$  por  $N$ , ou seja:  $\hat{P}_I = \hat{A}_I/N$  e  $\hat{P}_S = \hat{A}_S/N$ .

## Algoritmo para obter o IC exato para $A$

Procuramos os limites de confiança ótimos  $(\hat{A}_I, \hat{A}_S)$  que atendem aos requisitos definidos nas equações acima.

- ▶ Dada a população total conhecida  $N$ , o tamanho da amostra  $n$  e o número de unidades que pertencem a classe  $C$  na amostra  $a$ , podemos definir alguns limites de viabilidade para  $A$ :
  - ▶ Naturalmente, o menor valor que  $A$  pode assumir é o número observado (na amostra) de unidades que pertencem a classe  $C$ ,  $A_{min} = a$ .
  - ▶ O maior valor possível de  $A$  é igual ao número total  $N$  menos as observações na amostra que pertencem a classe  $C'$ , ou seja,  $A_{max} = N - (n - a)$ .


# Algoritmo para obter o IC exato para $A$

Limite superior  $\hat{A}_S$ :

- ▶ Comece com o maior valor possível para  $A$ , ou seja,  
 $A_{max} = N - (n - a)$ ;
- ▶ Então, diminua incrementalmente enquanto o  $\Pr(X \leq a) < \alpha/2$ , de modo que encontremos o maior valor possível que ainda satisfaz a equação.


# Algoritmo para obter o IC exato para $A$

- Suponha  $\alpha = 0,05$ .  $\Pr(X \leq a | \hat{A}_S = 70) < 0,025$ .



## Algoritmo para obter o IC exato para $A$


- Supondo  $\alpha = 0,05$ .  $\Pr(X \leq a | \hat{A}_S = 69) < 0,025$ .





# Algoritmo para obter o IC exato para $A$

$N = 100, n = 50, a_{\text{obs}} = 20$




# Algoritmo para obter o IC exato para $A$

## Limite inferior $\hat{A}_l$ :

- ▶ Comece com o menor valor possível para  $A$ , ou seja,  $A_{min} = a$ ;
- ▶ Reescrever
$$\Pr(X \geq a) = 1 - \Pr(X \leq a) = \alpha/2 \Leftrightarrow \Pr(X \leq a) = 1 - \alpha/2;$$
- ▶ Então, aumente incrementalmente enquanto  $\Pr(X \leq a) \geq 1 - \alpha/2$ , de modo que encontremos o menor valor possível que ainda preenche a equação.

# Algoritmo para obter o IC exato para $A$

$N = 100, n = 50, a_{\text{obs}} = 20$



## Exemplo

## Exemplo

- ▶ Em um **levantamento por amostragem**, utilizando **amostragem aleatória simples sem reposição**, de tamanho  $n = 100$ , de uma população de tamanho  $N = 500$ , foi observado que  $a = 37$  indivíduos são favoráveis a adoção de uma certa política pública (por exemplo, a adoção da **semana de 4 dias de trabalho**).
  - ▶ Os demais são contrários ou não sabem opinar.
- ▶ Os limites de confiança de 95% para a **proporção** e para o **número total de unidades** que pertencem a classe  $C$  (**favoráveis a adoção da política pública**) na população podem ser obtidos utilizando a aproximação normal e a distribuição hipergeométrica.

## Exemplo

### IC para $P$ utilizando aproximação normal

- ▶ O erro padrão estimado de  $p$  é

$$\sqrt{1-f} \sqrt{pq/(n-1)} = \sqrt{0,8} \sqrt{(0,37)(0,63)/99} = 0,0434.$$

- ▶ A correção de continuidade,  $1/2n$ , é igual a 0,005. Portanto, os limites de 95% para  $P$  podem ser estimados como

$$\begin{aligned} IC(P; 95\%) &= 0,37 \pm (1,96 \times 0,0434 + 0,005) \\ &= 0,37 \pm 0,090 = (0,280; 0,460). \end{aligned}$$

## Exemplo

### IC para $A$ utilizando aproximação normal

- Para achar os limites para o número total  $A$  de unidades da população que pertencem à categoria  $C$ , multiplicamos os valores acima por  $N$ :

$$\begin{aligned} IC(A; 95\%) &= (500 \times 0,280; 500 \times 0,460) \\ &= (140; 230) \end{aligned}$$

# Exemplo

## IC para $A$ e $P$ exato

- ▶ Como visto anteriormente, o intervalo de confiança exato é baseado na **distribuição hipergeométrica** (distribuição exata de  $a$ ) e requer a avaliação da distribuição acumulada.
- ▶ O pacote `samplingbook` do R possui uma função (`Sprop`) que facilita o trabalho do profissional de estatística.



## Exemplo

```
# install.packages("samplingbook")
library(samplingbook)

# ?Sprop
Sprop(m = 37, # m = a
      n = 100, N = 500, level = 0.95)

##
## Sprop object: Sample proportion estimate
## With finite population correction: N = 500
##
## Proportion estimate: 0.37
## Standard error: 0.0434
##
## 95% approximate confidence interval:
## proportion: [0.2849,0.4551]
## number in population: [143,227]
## 95% exact hypergeometric confidence interval:
## proportion: [0.284,0.464]
## number in population: [142,232]
```

# Considerações finais

# Considerações finais

## Sobre a aproximação normal

- ▶ Na maioria dos cenários, a construção do intervalo de confiança utilizando a aproximação normal resulta em propriedades satisfatórias.
- ▶ No entanto, se  $p$  estiver próximo de 0 ou 1, é recomendado usar o intervalo de confiança exato com base na distribuição hipergeométrica<sup>1</sup>.
- ▶ O intervalo aproximado tem uma **probabilidade de cobertura** tão baixa quanto  $n/N$  para qualquer  $\alpha$ . Portanto, não há garantia de que o intervalo capture o verdadeiro  $A$  com o nível de confiança desejado se a amostra for muito menor do que a população<sup>2</sup>.
- ▶ Ainda, com  $p$  e  $n$  pequenos, o IC aproximado pode produzir **limites inferiores** menores que 0.

---

<sup>1</sup>Kauermann, Goeran, and Helmut Kuechenhoff. 2010. *Stichproben: Methoden Und Praktische Umsetzung Mit R*. Springer-Verlag.

<sup>2</sup>Wang, Weizhen. 2015. Exact Optimal Confidence Intervals for Hypergeometric Parameters. *Journal of the American Statistical Association* 110 (512): 1491–9.

## Considerações finais

```
Sprop(m = 2, n = 30, # n e p pequenos
      N = 500, level = 0.95)

##
## Sprop object: Sample proportion estimate
## With finite population correction: N = 500
##
## Proportion estimate:  0.0667
## Standard error:  0.0449
##
## 95% approximate confidence interval:
##  proportion: [-0.0214,0.1547]
##  number in population: [-10,77]
## 95% exact hypergeometric confidence interval:
##  proportion: [0.008,0.218]
##  number in population: [4,109]
```

## Para casa

- ▶ Revisar os tópicos discutidos nesta aula.
- ▶ Rodar a simulação de Monte Carlo para avaliar as taxas de cobertura dos ICs para  $P$  considerando diferentes tamanhos de população, amostra, valores de  $P$  e de  $\alpha$ .
- ▶ Implementar o IC para  $P$  utilizando a distribuição binomial como aproximação da distribuição hipergeométrica.

## Próxima aula

- ▶ Porporações para classificações em mais de duas categorias.

# Por hoje é só!

Bons estudos!

